FACULDADE DE TECNOLOGIA DE INDAIATUBA

CURSO SUPERIOR DE TECNOLOGIA EM DESENVOLVIMENTO DE SOFTWARE MULTIPLATAFORMA

ARTHUR DAVI GOMES
GUSTAVO SILVA DE CARVALHO
MATHEUS HENRIQUE VIEIRA NEVES
RAUL TENORIO

Saúde Unificada: escalabilidade e custo da infraestrutura em nuvem

Indaiatuba
2026

FACULDADE DE TECNOLOGIA DE INDAIATUBA

CURSO SUPERIOR DE TECNOLOGIA EM DESENVOLVIMENTO DE SOFTWARE MULTIPLATAFORMA

ARTHUR DAVI GOMES

GUSTAVO SILVA DE CARVALHO

MATHEUS HENRIQUE VIEIRA NEVES

RAUL TENORIO

Saúde Unificada: escalabilidade e custo da infraestrutura em nuvem

Relatório técnico apresentado ao Projeto Integrador do 6º semestre do Curso Superior de Tecnologia em Desenvolvimento de Software Multiplataforma da Faculdade de Tecnologia de Indaiatuba, como parte das avaliações das disciplinas de Computação em Nuvem II e Qualidade e Teste de Software, elaborado sob a orientação do(a) Prof.(a) [nome do orientador].

Indaiatuba

2026

RESUMO

A plataforma Saúde Unificada centraliza, em um prontuário identificado pelo CPF, os dados de saúde de pacientes, com acesso por site, aplicativo e uma API implantada na nuvem da AWS. Este relatório verifica se o balanceamento de carga e o escalonamento automático da API funcionam e estima o custo de operar a plataforma em diferentes portes, até a rede hospitalar de todo o Brasil, com 1,5 a 2,5 milhões de atendimentos por dia. Realizaram-se testes de carga em três rodadas, mediu-se a capacidade de cada operação e simularam-se os custos em dez anos a partir de preços públicos de referência. Os resultados mostram que a API escalou de uma para três instâncias sob carga e voltou a uma sem carga, com vazão proporcional ao número de instâncias. Um defeito de conexão entre a API e o balanceador, que gerava até 3,14% de erros, foi identificado e corrigido, resultando em zero erros. Em escala nacional, a infraestrutura em nuvem custaria de R$ 30 a 47 mil por mês, e a operação realista, de R$ 317 a 374 mil por mês, abaixo de um centavo por atendimento. Mover para o S3 Glacier os dados com mais de 2,5 anos reduz em 44% a 46% o custo de dados em dez anos, sem descartar o prontuário, que a lei exige guardar por pelo menos 20 anos. A nuvem mostrou-se mais barata que uma infraestrutura própria, que só se torna competitiva quando o data center e a equipe já existem.

Palavras-chave: computação em nuvem; escalabilidade; prontuário eletrônico.

ABSTRACT

The Saúde Unificada platform centralizes patient health records identified by the Brazilian CPF, accessed through a website, a mobile app and an API deployed on AWS. This report verifies whether the API load balancing and auto scaling work and estimates the cost of operating the platform at different scales, up to the entire Brazilian hospital network, with 1.5 to 2.5 million visits per day. Load tests were run in three rounds, the capacity of each operation was measured and ten-year costs were simulated from public reference prices. The API scaled from one to three instances under load and back to one without load, with throughput proportional to the number of instances. A connection defect between the API and the load balancer, which caused up to 3.14% of errors, was found and fixed, resulting in zero errors. At national scale, the cloud infrastructure would cost BRL 30 to 47 thousand per month, and a realistic operation BRL 317 to 374 thousand per month, below one cent per visit. Moving data older than 2.5 years to S3 Glacier reduces ten-year data costs by 44% to 46% without deleting medical records, which Brazilian law requires to be kept for at least 20 years. The cloud proved cheaper than an on-premises infrastructure, which only becomes competitive when the data center and staff already exist.

Keywords: cloud computing; scalability; electronic health record.

LISTA DE GRÁFICOS

Gráfico 1 – CPU média e tarefas saudáveis durante a rodada 2.....13
Gráfico 2 – Taxa de erro por rodada e cenário.....15
Gráfico 3 – Capacidade de um processo da API por operação.....16
Gráfico 4 – Custo mensal de infraestrutura por porte.....17
Gráfico 5 – Custo mensal de banco e arquivos ao longo de dez anos.....21
Gráfico 6 – Composição do custo mensal no décimo ano, com arquivamento.....22
Gráfico 7 – Custo total em dez anos por tipo de infraestrutura.....23

LISTA DE QUADROS

Quadro 1 – Componentes da infraestrutura na nuvem.....10
Quadro 2 – Premissas de uso para a estimativa por porte.....16
Quadro 3 – Possibilidade de descarte por tipo de dado.....19
Quadro 4 – Local de armazenamento conforme a idade do dado.....20
Quadro 5 – Premissas da simulação de dez anos.....20
Quadro 6 – Componentes de uma infraestrutura própria.....22

LISTA DE TABELAS

Tabela 1 – Cenários dos testes de carga na AWS.....11
Tabela 2 – Resultados dos testes de carga por rodada.....13
Tabela 3 – Linha do tempo do escalonamento automático (horário de Brasília).....14
Tabela 4 – Capacidade medida em computador local e estimada para uma tarefa na AWS.....16
Tabela 5 – Custo mensal estimado da infraestrutura por porte (US$).....17
Tabela 6 – Requisições geradas por atendimento.....18
Tabela 7 – Volume e capacidade necessários no cenário nacional.....18
Tabela 8 – Custo mensal estimado no cenário nacional (US$).....18
Tabela 9 – Evolução anual no cenário de 1,5 milhão de atendimentos por dia.....20
Tabela 10 – Evolução anual no cenário de 2,5 milhões de atendimentos por dia.....21
Tabela 11 – Custo total de banco e arquivos em dez anos.....22
Tabela 12 – Custo total em dez anos: nuvem e infraestrutura própria (R$ milhões). 23
Tabela 13 – Arquivos em infraestrutura própria e na nuvem em dez anos (modelo híbrido).....24
Tabela 14 – Infraestrutura isolada e operação realista na nuvem.....24

LISTA DE ABREVIATURAS E SIGLAS

ABNT	Associação Brasileira de Normas Técnicas
ALB	Application Load Balancer
API	Application Programming Interface (interface de programação de aplicações)
AWS	Amazon Web Services
CDK	Cloud Development Kit
CDN	Content Delivery Network (rede de distribuição de conteúdo)
CFM	Conselho Federal de Medicina
CORS	Cross-Origin Resource Sharing (compartilhamento entre origens)
CPF	Cadastro de Pessoas Físicas
CPU	Central Processing Unit (unidade central de processamento)
CRM	Conselho Regional de Medicina
DDoS	Distributed Denial of Service (ataque distribuído de negação de serviço)
ECS	Elastic Container Service
FHIR	Fast Healthcare Interoperability Resources
HL7	Health Level Seven
HTTPS	Hypertext Transfer Protocol Secure
ICP-Brasil	Infraestrutura de Chaves Públicas Brasileira
JSON	JavaScript Object Notation
JWT	JSON Web Token
LGPD	Lei Geral de Proteção de Dados Pessoais
PB	Petabyte
PDF	Portable Document Format
S3	Simple Storage Service
SHA-256	Secure Hash Algorithm de 256 bits
SSD	Solid State Drive
TB	Terabyte
vCPU	Virtual CPU (processador virtual)
WAF	Web Application Firewall

SUMÁRIO

1 INTRODUÇÃO.....9
2 ARQUITETURA E FUNCIONAMENTO DO BALANCEAMENTO.....10
2.1 Arquitetura implantada na AWS.....10
2.2 Balanceamento de carga e escalonamento automático.....10
3 PROCEDIMENTOS METODOLÓGICOS.....11
3.1 Testes de carga.....11
3.2 Medição da capacidade por operação.....11
3.3 Estimativa de custos.....12
4 RESULTADOS E DISCUSSÃO.....13
4.1 Testes de carga na AWS.....13
4.2 Defeito de conexão encontrado e corrigido.....14
4.3 Distribuição desigual da carga.....15
4.4 Capacidade por operação.....15
4.5 Custo conforme o porte.....16
4.6 Cenário de abrangência nacional.....17
4.7 Banco de dados e arquivos ao longo de dez anos.....19
4.7.1 O que a legislação permite descartar.....19
4.7.2 Política de armazenamento por idade do dado.....19
4.7.3 Resultados da simulação.....20
4.8 Infraestrutura própria em comparação com a nuvem.....22
4.9 Realismo da estimativa.....24
5 CONSIDERAÇÕES FINAIS.....26
REFERÊNCIAS.....27

1 Introdução

A plataforma Saúde Unificada reúne, em um prontuário único identificado pelo CPF, as informações de saúde de cada paciente: alergias, medicamentos em uso, cirurgias, exames, condições clínicas e o histórico de atendimentos. O sistema é composto por um site para profissionais de saúde e gestores públicos, um aplicativo para pacientes e uma API compartilhada, implantada na nuvem da *Amazon Web Services* (AWS).

Além do comportamento funcional, um sistema desse tipo precisa continuar respondendo quando o número de usuários cresce e manter o custo sob controle. Por isso, busca-se também responder a duas perguntas: o balanceamento de carga e o escalonamento automático (*auto scaling*) implantados funcionam na prática? E quanto custaria operar a plataforma se ela fosse adotada em escala, chegando à rede hospitalar de todo o Brasil?

Os objetivos são: verificar, com testes de carga na AWS, se a API distribui as requisições entre várias instâncias e aumenta ou reduz a quantidade de instâncias conforme a demanda; medir a capacidade de cada instância e estimar o custo mensal e em dez anos da infraestrutura para diferentes portes, comparando a nuvem com uma infraestrutura própria.

Trata-se de uma pesquisa aplicada, de caráter quantitativo, baseada em testes controlados e em simulação de custos a partir de premissas declaradas. Além desta introdução, o documento apresenta a arquitetura e o funcionamento do balanceamento (seção 2), os procedimentos metodológicos (seção 3), os resultados e a discussão (seção 4) e as considerações finais (seção 5).

2 Arquitetura e funcionamento do balanceamento

2.1 Arquitetura implantada na AWS

A API foi implantada na região da Virgínia do Norte (us-east-1), escolhida por ser a mais barata e por ser uma das liberadas para a conta utilizada no projeto. Toda a infraestrutura é descrita como código, com o AWS CDK, o que permite criá-la e removê-la por comandos, sem configuração manual. O Quadro 1 resume os componentes.

Quadro 1 – Componentes da infraestrutura na nuvem

Componente	Função no sistema
Amazon CloudFront	Recebe as requisições dos usuários com HTTPS e as encaminha ao balanceador de carga
Application Load Balancer (ALB)	Distribui as requisições entre as instâncias da API e só aceita tráfego vindo do CloudFront
Amazon ECS com Fargate Spot	Executa a API em contêineres (tarefas) de 0,25 vCPU e 512 MB, de 1 a 3 tarefas
Auto scaling do ECS	Aumenta ou reduz o número de tarefas conforme o uso médio de CPU
MongoDB Atlas	Banco de dados dos prontuários, atendimentos e auditoria
Amazon S3	Armazenamento das receitas, laudos e exames em PDF
Amazon CloudWatch e SNS	Métricas, painel de monitoramento, alarmes e avisos por e-mail

Fonte: Elaborado pelos autores (2026).

2.2 Balanceamento de carga e escalonamento automático

O balanceador de carga recebe todas as requisições e as distribui entre as tarefas saudáveis, isto é, aquelas que respondem à verificação de saúde em */api/health/live*. O escalonamento automático observa a CPU média do serviço a cada minuto: quando ela passa de 50%, uma nova tarefa é criada, até o limite de três; quando permanece abaixo de 45% por 15 minutos, uma tarefa é removida. Uma tarefa nova leva cerca de um minuto e meio para começar a receber requisições.

A demora intencional para reduzir o número de tarefas evita que o sistema desligue instâncias em uma pausa curta da demanda e precise criá-las de novo logo em seguida.

3 Procedimentos metodológicos

3.1 Testes de carga

Os testes utilizaram um script próprio, escrito em Node.js, que simula usuários simultâneos fazendo login sem parar. O login foi escolhido por ser a operação mais pesada da API: a verificação da senha com o algoritmo bcrypt consome CPU de propósito, para dificultar ataques às senhas. Isso faz a CPU subir rapidamente e permite observar o escalonamento. Durante os testes, o limite de tentativas de login foi desligado e religado ao final. A Tabela 1 descreve os cenários.

Tabela 1 – Cenários dos testes de carga na AWS

Cenário	Configuração	Usuários simultâneos	Duração	Objetivo
C02	1 tarefa fixa	20	5 min	Capacidade de uma tarefa
C03	Escalonamento de 1 a 3 tarefas	20	10 min	Verificar o aumento de tarefas
C04	Sem carga, após o C03	0	~20 min	Verificar a redução para 1 tarefa

Fonte: Elaborado pelos autores (2026).

Foram realizadas três rodadas. A primeira revelou erros de conexão; após a correção (seção 4.2), a segunda rodada repetiu os cenários. A terceira rodada foi executada a partir de outra cópia do projeto, ainda sem a correção, o que permitiu confirmar a causa do problema. As métricas de CPU, tarefas saudáveis, requisições e tempo de resposta foram exportadas do Amazon CloudWatch.

3.2 Medição da capacidade por operação

Para estimar o custo de uso real, que mistura logins e consultas, mediu-se a capacidade de um processo da API em computador local (AMD Ryzen 5 5600GT) para cinco operações, com dez usuários simultâneos. A proporção entre o resultado local e o medido na AWS para o login foi usada para estimar a capacidade de uma tarefa na nuvem nas demais operações.

3.3 Estimativa de custos

Os custos foram calculados a partir dos preços públicos de referência da AWS e do MongoDB Atlas, sob demanda, convertidos com o dólar a R$ 5,50. Os valores são aproximados e devem ser conferidos na calculadora oficial antes de qualquer uso formal (Amazon Web Services, 2026a; MongoDB, 2026). As premissas de uso foram definidas pela equipe, e o número de atendimentos diários na rede hospitalar brasileira (1,5 a 2,5 milhões) é uma estimativa adotada pela equipe, e não um dado oficial.

4 Resultados e discussão

4.1 Testes de carga na AWS

A Tabela 2 apresenta os resultados das três rodadas. Em todas, o escalonamento automático aumentou o serviço de uma para três tarefas durante a carga e voltou a uma tarefa depois dela.

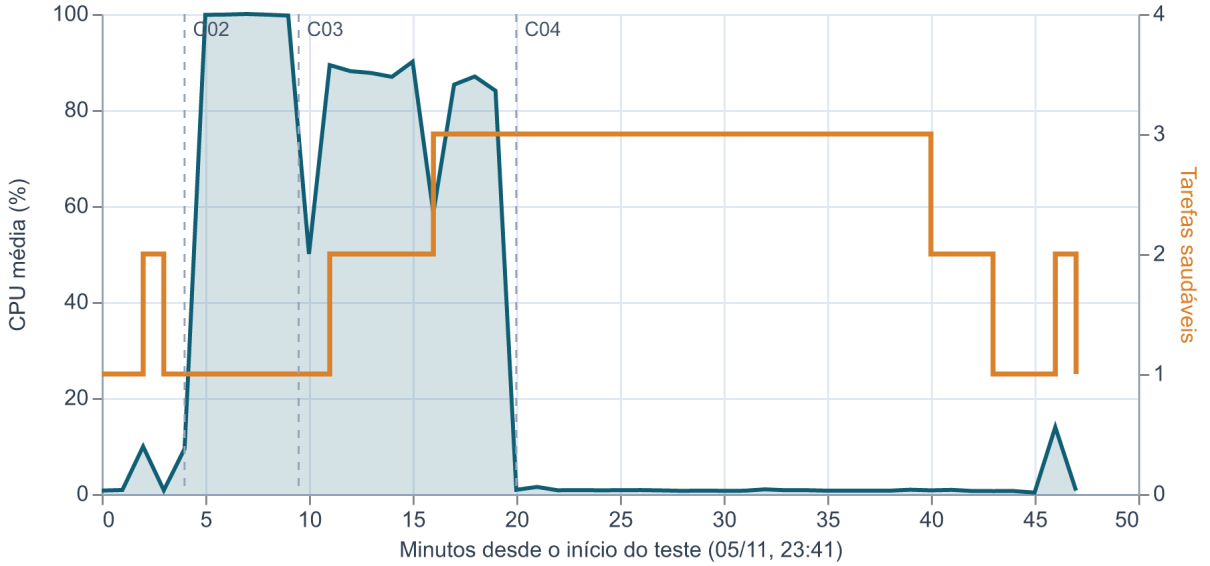
Tabela 2 – Resultados dos testes de carga por rodada

Rodada	Versão da API	C02: vazão	C02: erros	C03: vazão	C03: erros	Tarefas
1 (05/11, 22h58)	Sem a correção	2,8 req/s	1,65%	6,0 req/s	1,09%	1 → 3 → 1
2 (05/11, 23h45)	Com a correção	2,8 req/s	0%	4,7 req/s	0%	1 → 3 → 1
3 (06/11, 01h13)	Sem a correção	2,9 req/s	3,14%	5,9 req/s	1,21%	1 → 3 → 1

Fonte: Elaborado pelos autores (2026), com dados dos testes de carga e do Amazon CloudWatch.

O Gráfico 1 mostra, minuto a minuto, a CPU média do serviço e o número de tarefas saudáveis durante a rodada 2. Com uma tarefa (C02), a CPU permanece em 100%. Ao liberar o escalonamento (C03), a CPU passa de 50% e o serviço sobe para duas e depois três tarefas. Sem carga (C04), a CPU cai para perto de zero e, cerca de 20 minutos depois, o serviço volta a uma tarefa, como detalha a Tabela 3.

Gráfico 1 – CPU média e tarefas saudáveis durante a rodada 2



Fonte: Elaborado pelos autores (2026), com dados do Amazon CloudWatch.

Tabela 3 – Linha do tempo do escalonamento automático (horário de Brasília)

Rodada	Subiu para 2	Subiu para 3	Fim da carga	Desceu para 2	Voltou para 1
1	23h04	23h10	23h13	23h31	23h34
2	23h51	23h57	00h00	00h21	00h24

Fonte: Elaborado pelos autores (2026), com dados do histórico do *auto scaling* da AWS.

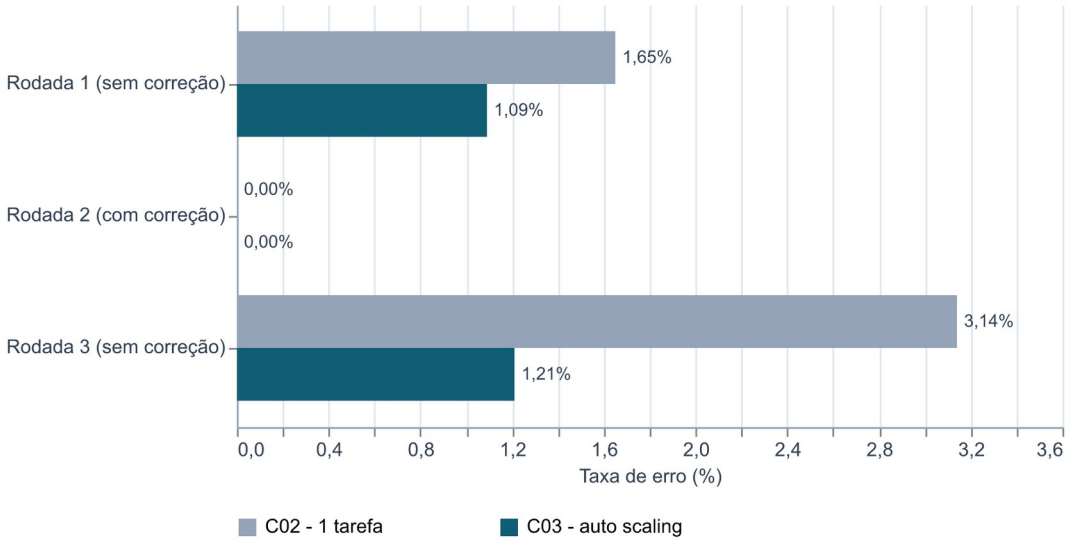
Na rodada 1, com três tarefas ao final da carga, a vazão chegou a 8,4 logins por segundo, o triplo da obtida com uma tarefa (2,8 por segundo). O crescimento proporcional ao número de tarefas indica que a aplicação escala horizontalmente. O alarme de lentidão (tempo de resposta acima de 2 segundos) também disparou durante a carga e avisou por e-mail quando a situação se normalizou, o que confirma o funcionamento do monitoramento.

4.2 Defeito de conexão encontrado e corrigido

Nas rodadas sem a correção, a taxa de erro ficou entre 1,09% e 3,14%, acima do critério de aceitação de 1%, conforme o Gráfico 2. Todos os erros eram respostas 502 geradas pelo próprio balanceador de carga; a API não registrou nenhuma falha. A causa é a diferença entre os tempos de conexão ociosa: o Node.js encerra uma conexão parada após 5 segundos, enquanto o balanceador a reaproveita por até 60 segundos. Quando o balanceador envia uma requisição por uma conexão que acabou de ser encerrada, devolve erro ao usuário.

A correção consistiu em fazer a API manter a conexão por 65 segundos, mais do que o balanceador. Na rodada 2, com a correção, foram 3.659 requisições sem nenhum erro. A rodada 3, executada com uma versão sem a correção, voltou a apresentar erros, o que confirma a causa.

Gráfico 2 – Taxa de erro por rodada e cenário



Fonte: Elaborado pelos autores (2026), com dados dos testes de carga.

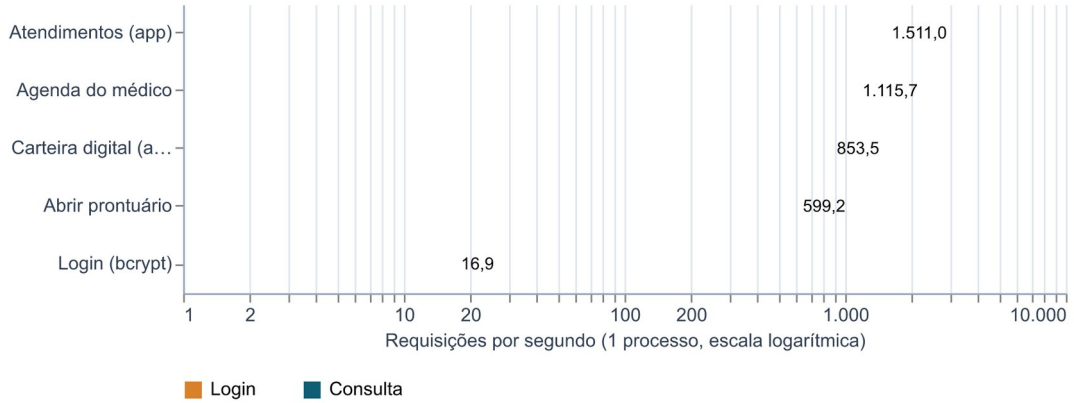
4.3 Distribuição desigual da carga

Na rodada 2, com três tarefas, o tempo de resposta típico (mediana) caiu de 7,3 segundos para cerca de 1 segundo, mas os 5% de requisições mais lentas continuaram perto de 8,5 segundos, e a CPU média ficou em 87%, e não em 100%. Isso indica que uma das tarefas recebeu mais trabalho que as demais. O balanceador distribui por quantidade de requisições (*round robin*), mas um login demora muito mais que outras operações. Como melhoria, propõe-se trocar o algoritmo para *least outstanding requests*, que envia cada requisição à tarefa com menos trabalho pendente, e repetir o cenário C03.

4.4 Capacidade por operação

O Gráfico 3 e a Tabela 4 mostram que as consultas são de 35 a 90 vezes mais leves que o login. Para as estimativas de custo, considerou-se uma mistura de 5% de logins e 95% de consultas, todas tão pesadas quanto abrir o prontuário (cenário pessimista). Nessas condições, uma tarefa de 0,25 vCPU atende cerca de 36 requisições por segundo com a CPU em 100%, ou 18 requisições por segundo com o alvo de 50% do escalonamento automático.

Gráfico 3 – Capacidade de um processo da API por operação



Fonte: Elaborado pelos autores (2026), com dados de medição local.

Tabela 4 – Capacidade medida em computador local e estimada para uma tarefa na AWS

Operação	Local (1 processo)	AWS (0,25 vCPU)
Login (bcrypt)	16,9 req/s	2,8 req/s (medido)
Abrir prontuário (com auditoria)	599 req/s	~100 req/s
Agenda do médico	1.116 req/s	~185 req/s
Carteira digital (aplicativo)	854 req/s	~140 req/s
Atendimentos do paciente (aplicativo)	1.511 req/s	~250 req/s

Fonte: Elaborado pelos autores (2026).

Nota: os valores da AWS, exceto o login, aplicam a proporção medida no login (2,8 ÷ 16,9 = 0,17).

4.5 Custo conforme o porte

Para estimar o custo por porte, adotaram-se as premissas do Quadro 2. O pico de requisições por segundo foi calculado como o número de pacientes multiplicado por 20 requisições e dividido pelos segundos de 30 dias de 12 horas, multiplicado pelo fator de pico.

Quadro 2 – Premissas de uso para a estimativa por porte

Premissa	Valor adotado	Justificativa
Requisições por paciente por mês	20	Abrir o aplicativo duas vezes por mês e as consultas do médico no atendimento
Horário de uso	12 horas por dia	Funcionamento das unidades de saúde e uso diurno do aplicativo
Pico	3 vezes a média	Manhãs de segunda-feira e campanhas de vacinação
Documentos	2 por paciente por ano, 300 KB cada	Receitas e laudos em PDF
Câmbio	R$ 5,50 por dólar	—

Fonte: Elaborado pelos autores (2026).

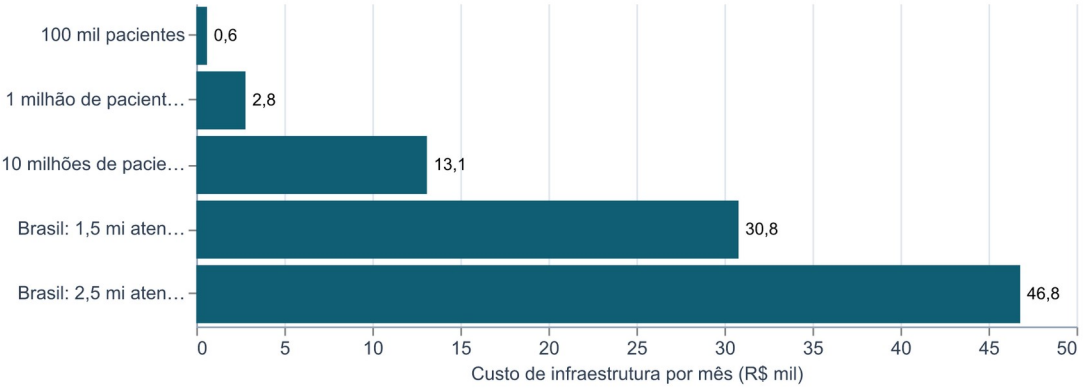
Tabela 5 – Custo mensal estimado da infraestrutura por porte (US$)

Item	100 mil pacientes	1 milhão	10 milhões
Tarefas da API (Fargate, sob demanda)	18	27	252
Balanceador de carga	17	18	24
Endereços IP públicos	15	18	33
CloudFront	0	22	418
MongoDB Atlas	58	394	1.460
Amazon S3 (documentos)	2	16	160
CloudWatch	1	3	15
Redis (limite de login entre tarefas)	—	12	23
Total por mês	**110 (R$ 600)**	**510 (R$ 2.800)**	**2.390 (R$ 13.100)**
Por 1 milhão de requisições	R$ 300	R$ 140	R$ 65

Fonte: Elaborado pelos autores (2026), com base nos preços de referência da AWS e do MongoDB Atlas.

Observa-se que, quanto maior o porte, menor o custo por paciente, pois a parte fixa (balanceador e banco de dados) se divide entre mais usuários. No porte de 1 milhão de pacientes, o banco de dados representa cerca de 77% do custo, e o maior volume nele é a trilha de auditoria. O Gráfico 4 compara os portes, incluindo o cenário de abrangência nacional, detalhado na seção seguinte.

Gráfico 4 – Custo mensal de infraestrutura por porte



Fonte: Elaborado pelos autores (2026).

4.6 Cenário de abrangência nacional

Considerou-se o caso extremo de toda a rede hospitalar brasileira usar a plataforma, com 1,5 a 2,5 milhões de atendimentos por dia, incluindo pronto-socorro, exames e internações. A Tabela 6 apresenta quantas requisições cada atendimento gera.

Tabela 6 – Requisições geradas por atendimento

Ação	Requisições
Médico abre o prontuário	1
Médico consulta o histórico do paciente	1
Atualização da agenda do médico	1
Registro do atendimento	1
Envio de receita ou laudo	1
Download ou conferência de um documento	1
Paciente consulta o aplicativo depois	2
Logins (médico a cada 20 pacientes; metade dos pacientes no aplicativo)	0,55
Total por atendimento	**8,55**

Fonte: Elaborado pelos autores (2026).

Com 70% do movimento entre 7h e 19h e um pico igual ao dobro da média desse horário, obtêm-se os volumes da Tabela 7. A capacidade usada foi de cerca de 62 requisições por segundo por vCPU, com o escalonamento em 50%.

Tabela 7 – Volume e capacidade necessários no cenário nacional

Indicador	1,5 milhão/dia	2,5 milhões/dia
Requisições por dia	12,8 milhões	21,4 milhões
Requisições por mês	385 milhões	641 milhões
Pico	416 req/s	693 req/s
vCPUs no pico	6,7 (7 tarefas de 1 vCPU)	11,2 (12 tarefas de 1 vCPU)
Tráfego de saída por mês	~1,9 TB	~3,2 TB
Documentos novos por mês	~6,8 TB	~11 TB
Crescimento do banco por ano	~1,2 TB	~2 TB

Fonte: Elaborado pelos autores (2026).

Tabela 8 – Custo mensal estimado no cenário nacional (US$)

Item	1,5 milhão/dia	2,5 milhões/dia
Tarefas da API (Fargate)	104	157
Balanceador de carga	32	42
Endereços IP públicos	22	29
CloudFront	926	1.632
MongoDB Atlas	~3.200	~4.500
Amazon S3 (documentos, ao fim do 1º ano)	~1.000	~1.670
CloudWatch	25	35
Redis	47	47
WAF (firewall de aplicação)	240	395
Total por mês	**~5.600 (R$ 30.800)**	**~8.500 (R$ 46.800)**
Custo por atendimento	R$ 0,0007	R$ 0,0006

Fonte: Elaborado pelos autores (2026), com base nos preços de referência da AWS e do MongoDB Atlas.

Os servidores da API representam apenas cerca de 2% do custo: de 7 a 12 tarefas de 1 vCPU atendem o pico do país, bastando elevar o limite do escalonamento automático. O custo está concentrado nos dados, com o banco respondendo por 53% a 57% do total e os documentos por cerca de 20%. Mesmo nesse cenário, o custo por atendimento fica abaixo de um décimo de centavo.

4.7 Banco de dados e arquivos ao longo de dez anos

4.7.1 O que a legislação permite descartar

Antes de propor o descarte de dados antigos, é necessário verificar os prazos legais. A Lei nº 13.787/2018 estabelece que os prontuários podem ser eliminados somente após o prazo mínimo de 20 anos a partir do último registro (Brasil, 2018b), e parte das interpretações da Resolução CFM nº 1.821/2007 aponta guarda permanente para o prontuário nativamente eletrônico (Conselho Federal de Medicina, 2007; 2026). O Quadro 3 resume a situação de cada tipo de dado.

Quadro 3 – Possibilidade de descarte por tipo de dado

Dado	Pode ser descartado após 5 anos?	Fundamento
Prontuário (documento do paciente e histórico de atendimentos)	Não	Mínimo de 20 anos após o último registro (Brasil, 2018b); possível guarda permanente para o eletrônico (Conselho Federal de Medicina, 2007)
Receitas, laudos e exames anexados	Não	Fazem parte do prontuário
Trilha de auditoria (registro de acessos)	Sim, por política adotada	Não é prontuário; o Marco Civil da Internet exige ao menos 6 meses (Brasil, 2014). Adotou-se guarda de 5 anos

Fonte: Elaborado pelos autores (2026).

Assim, em dez anos nenhum dado do prontuário é descartado. A economia vem de mover os dados antigos para armazenamento de baixo custo (S3 Glacier), e não de apagá-los.

4.7.2 Política de armazenamento por idade do dado

O modelo da API mantém um documento por paciente, atualizado a cada atendimento pelo médico responsável, e registros separados para o histórico de

atendimentos e para a auditoria. Os arquivos ficam no S3. O Quadro 4 apresenta onde cada dado fica conforme sua idade.

Quadro 4 – Local de armazenamento conforme a idade do dado

Idade	Documento do paciente	Histórico de atendimentos	Auditoria	PDFs
Até 90 dias	Atlas	Atlas	Atlas	S3 Standard
90 dias a 2,5 anos	Atlas	Atlas	Atlas	S3 Standard-IA
Mais de 2,5 anos	Atlas (sempre o atual)	S3 Glacier Instant Retrieval	S3 Glacier Deep Archive	S3 Glacier Instant Retrieval
Mais de 5 anos	Atlas	Glacier	Descartada	Glacier

Fonte: Elaborado pelos autores (2026).

O Glacier Instant Retrieval devolve o arquivo em milissegundos, de modo que o médico continua abrindo um exame antigo normalmente, com armazenamento cerca de seis vezes mais barato que o S3 comum (Amazon Web Services, 2026c).

4.7.3 Resultados da simulação

Quadro 5 – Premissas da simulação de dez anos

Premissa	Valor adotado
Pacientes cadastrados	80 milhões no 1º ano, 150 milhões no 5º e 190 milhões no 10º
Documento do paciente	8 KB, crescendo até 10 KB em dez anos
Cada atendimento	1,5 KB de histórico e 0,75 KB de auditoria
PDFs	Metade dos atendimentos gera um arquivo de 300 KB
Compactação ao arquivar	O JSON arquivado ocupa 30% do tamanho original
Custo do Atlas	US$ 1,50 por GB por mês, incluindo três cópias, backup e servidores
Preços do S3 (por GB por mês)	Standard US$ 0,023; Standard-IA 0,0125; Glacier Instant Retrieval 0,004; Glacier Deep Archive 0,00099

Fonte: Elaborado pelos autores (2026).

Tabela 9 – Evolução anual no cenário de 1,5 milhão de atendimentos por dia

Ano	Pacientes	Dados no Atlas	Histórico no Glacier	PDFs	Custo no mês (US$)	Sem arquivar (US$)
1	80 mi	1,9 TB	—	82 TB	4.074	4.074
3	120 mi	4,1 TB	0,2 TB	246 TB	9.115	10.388
5	150 mi	4,4 TB	0,9 TB	411 TB	10.251	16.614
7	166 mi	4,6 TB	1,4 TB	575 TB	11.226	22.679
10	190 mi	5,0 TB	2,2 TB	821 TB	12.724	31.813

Fonte: Elaborado pelos autores (2026).

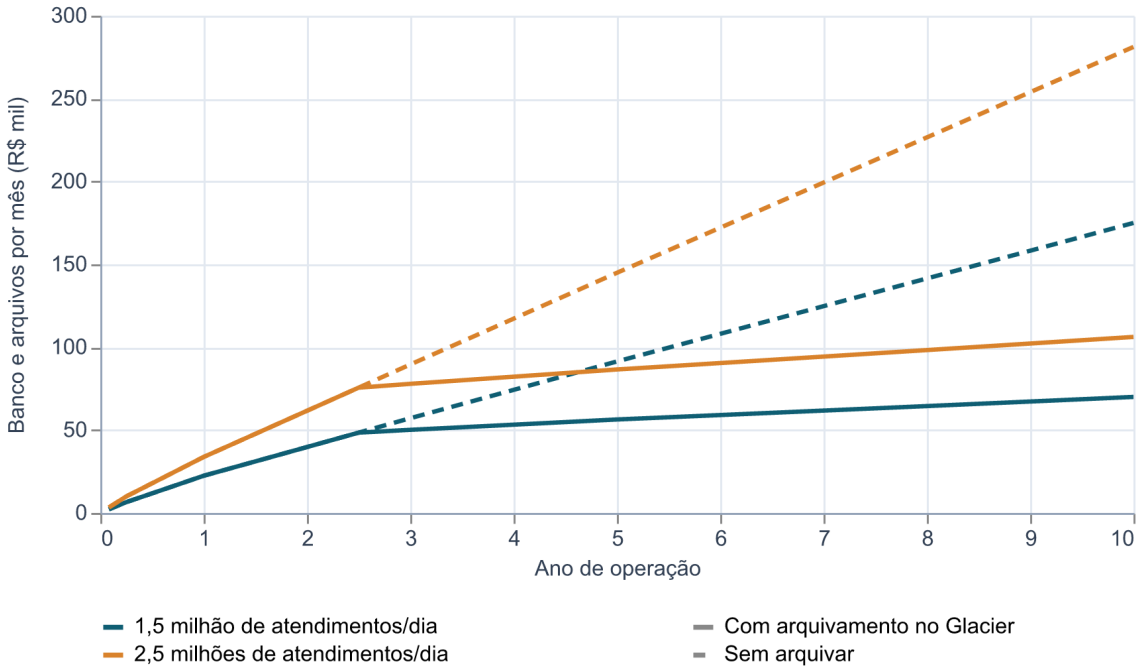
Tabela 10 – Evolução anual no cenário de 2,5 milhões de atendimentos por dia

Ano	Pacientes	Dados no Atlas	Histórico no Glacier	PDFs	Custo no mês (US$)	Sem arquivar (US$)
1	80 mi	2,7 TB	—	137 TB	6.134	6.134
3	120 mi	6,2 TB	0,3 TB	411 TB	14.160	16.281
5	150 mi	6,5 TB	1,5 TB	684 TB	15.736	26.340
7	166 mi	6,7 TB	2,4 TB	958 TB	17.150	36.238
10	190 mi	7,0 TB	3,6 TB	1.369 TB	19.307	51.121

Fonte: Elaborado pelos autores (2026).

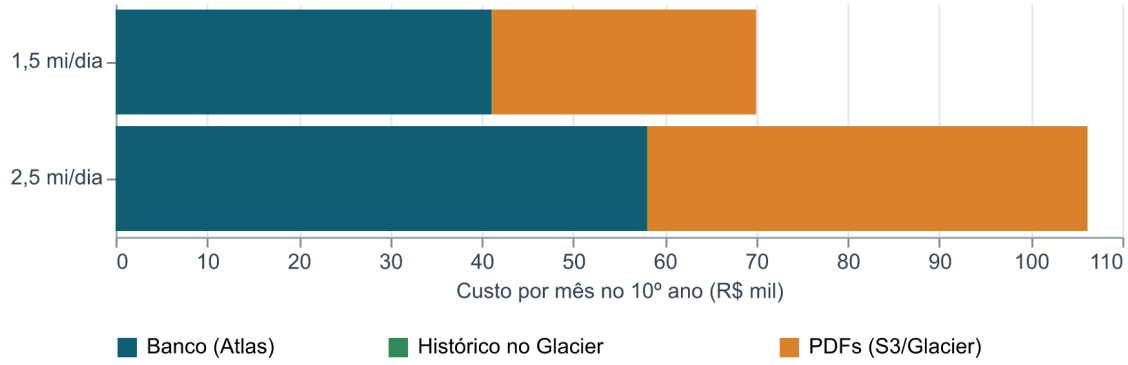
O Gráfico 5 mostra que, com o arquivamento, o custo mensal deixa de crescer na mesma velocidade a partir de 2,5 anos, pois o banco se estabiliza entre 5 e 7 TB. Sem arquivamento, o banco chegaria a 14 a 22 TB e o custo seria cerca de três vezes maior. O Gráfico 6 mostra que, no décimo ano, os PDFs passam a representar de 40% a 45% do custo.

Gráfico 5 – Custo mensal de banco e arquivos ao longo de dez anos



Fonte: Elaborado pelos autores (2026).

Gráfico 6 – Composição do custo mensal no décimo ano, com arquivamento



Fonte: Elaborado pelos autores (2026).

Tabela 11 – Custo total de banco e arquivos em dez anos

Política	1,5 milhão/dia	2,5 milhões/dia
Com arquivamento no Glacier	US$ 1,12 milhão (~R$ 6,2 milhões)	US$ 1,72 milhão (~R$ 9,5 milhões)
Sem arquivamento	US$ 1,99 milhão (~R$ 10,9 milhões)	US$ 3,17 milhões (~R$ 17,4 milhões)
Economia	44%	46%

Fonte: Elaborado pelos autores (2026).

Para reduzir ainda mais o custo, os PDFs com mais de cinco anos podem ir para o Glacier Deep Archive, quatro vezes mais barato, com recuperação em até 12 horas, o que economizaria cerca de US$ 1.200 por mês no décimo ano do cenário menor. Comprimir as imagens dos exames digitalizados também reduziria o volume.

4.8 Infraestrutura própria em comparação com a nuvem

Avaliou-se a alternativa de construir infraestrutura dedicada, separada em uma estrutura para os dados e outra para a API e o site, cada uma em dois *data centers* (principal e contingência), como exige um sistema nacional de saúde. O Quadro 6 descreve os componentes.

Quadro 6 – Componentes de uma infraestrutura própria

Estrutura	Componentes em cada data center	Equivalente na AWS
Dados	Três servidores de banco com SSD NVMe; armazenamento de objetos próprio (Ceph ou MinIO) com cerca de 1 a 1,7 PB úteis em dez anos; biblioteca de fitas LTO na contingência	MongoDB Atlas, S3 e Glacier
Aplicação	Três servidores para API e site, par de firewalls e balanceadores, switches, dois links de internet e proteção contra DDoS	ECS Fargate, ALB, CloudFront e WAF

Fonte: Elaborado pelos autores (2026).

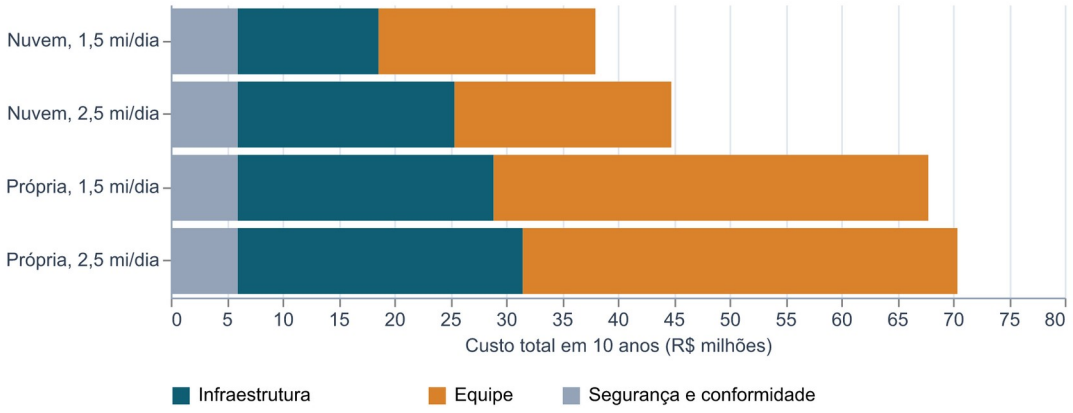
Para uma comparação justa, ambas as opções incluem contingência, dados no Brasil, suporte do fornecedor, equipe de operação e segurança. A Tabela 12 e o Gráfico 7 apresentam o resultado.

Tabela 12 – Custo total em dez anos: nuvem e infraestrutura própria (R$ milhões)

Item	Nuvem 1,5 mi/dia	Nuvem 2,5 mi/dia	Própria 1,5 mi/dia	Própria 2,5 mi/dia
Banco e arquivos	6,2	9,5	—	—
API, site, CDN e firewall	0,9	1,5	—	—
Contingência em outra região	2,2	3,3	incluída	incluída
Região São Paulo (~35% mais cara)	2,5	3,9	—	—
Suporte do fornecedor (~7%)	0,8	1,3	—	—
Equipamentos (compra e troca no 5º ano)	—	—	4,9	5,6
Manutenção dos equipamentos	—	—	2,4	2,8
Espaço em data center (R$ 12 mil por rack/mês)	—	—	7,2	8,6
Links de internet e enlace entre sites	—	—	6,6	6,6
Proteção contra DDoS	—	—	1,8	1,8
Subtotal de infraestrutura	**12,6**	**19,4**	**22,9**	**25,5**
Equipe de operação (R$ 18 mil + encargos)	19,4	19,4	38,9	38,9
Segurança e conformidade	6,0	6,0	6,0	6,0
Total em dez anos	**38**	**45**	**68**	**70**
Média por mês (R$ mil)	317	374	565	586

Fonte: Elaborado pelos autores (2026).

Gráfico 7 – Custo total em dez anos por tipo de infraestrutura



Fonte: Elaborado pelos autores (2026).

O equipamento é a menor parte do custo da infraestrutura própria, cerca de R$ 5 milhões em dez anos. O que pesa é o espaço com energia e refrigeração, os links redundantes, os contratos de manutenção e, principalmente, a equipe de plantão 24

horas, estimada em dez pessoas, contra cinco na nuvem, onde parte do trabalho é feita pelo fornecedor.

Tabela 13 – Arquivos em infraestrutura própria e na nuvem em dez anos (modelo híbrido)

Opção	1,5 milhão/dia	2,5 milhões/dia
PDFs na nuvem (região São Paulo)	~R$ 3,0 milhões	~R$ 5,1 milhões
PDFs em armazenamento próprio, com fitas, espaço, enlace e três pessoas de plantão	~R$ 20,6 milhões	~R$ 21,2 milhões

Fonte: Elaborado pelos autores (2026).

Manter apenas os arquivos em infraestrutura própria também não compensa nesse volume, como mostra a Tabela 13. A infraestrutura própria se torna competitiva quando o *data center* e a equipe já existem, como ocorre em órgãos públicos como DATASUS, Serpro e Dataprev: sem aluguel de espaço e com equipe compartilhada, o custo cai para cerca de R$ 33 a 35 milhões em dez anos, próximo ao da nuvem. Também compensa em escalas muito maiores ou quando há exigência de soberania de dados que impeça a nuvem pública. A arquitetura adotada permite essa migração sem reescrever a API, pois MongoDB e armazenamentos compatíveis com S3 funcionam em qualquer ambiente.

4.9 Realismo da estimativa

As estimativas das seções 4.5 a 4.7 consideram apenas a infraestrutura, com preços de referência na região da Virgínia. Essa parte está na ordem de grandeza correta, mas o custo de operar um sistema desse tamanho é de quatro a cinco vezes maior, como mostra a Tabela 14.

Tabela 14 – Infraestrutura isolada e operação realista na nuvem

Indicador	Somente infraestrutura (Virgínia)	Operação realista
Total em dez anos	R$ 7 a 11 milhões	R$ 38 a 45 milhões
Média por mês	R$ 59 a 92 mil	R$ 317 a 374 mil
Custo por atendimento	~R$ 0,0013	~R$ 0,005 a 0,007

Fonte: Elaborado pelos autores (2026).

A operação realista acrescenta a região de São Paulo, a contingência, o suporte do fornecedor, a equipe de operação, que representa mais da metade do custo, e a segurança. Ainda ficam fora da estimativa itens que, em um projeto real, podem superar todos os anteriores:

a) equipe de desenvolvimento contínuo do sistema;
b) integração com os sistemas de cada hospital, nos padrões HL7 e FHIR;
c) central de suporte a médicos e pacientes, e treinamento;
d) assessoria jurídica e encarregado de dados, conforme a LGPD (Brasil, 2018a);
e) certificados digitais ICP-Brasil para assinatura das receitas.

5 Considerações finais

Os testes na AWS mostraram que o balanceamento de carga e o escalonamento automático funcionam: a API aumentou de uma para três tarefas sob carga, voltou a uma tarefa sem carga e teve vazão proporcional ao número de tarefas. Permanece como melhoria a distribuição desigual da carga entre as tarefas, para a qual se propõe a troca do algoritmo de balanceamento.

Quanto ao custo, a infraestrutura em nuvem para o país inteiro custaria de R$ 30 a 47 mil por mês, e a operação realista, com equipe, contingência e segurança, de R$ 317 a 374 mil por mês, sempre abaixo de um centavo por atendimento. O maior custo está nos dados, e não nos servidores da API. Em dez anos, mover para o Glacier os dados com mais de 2,5 anos reduz em 44% a 46% o custo de banco e arquivos, sem descartar nenhum dado do prontuário, que deve ser guardado por pelo menos 20 anos. Para o porte do projeto, a nuvem se mostrou mais barata que uma infraestrutura própria, que só se torna competitiva quando o *data center* e a equipe já existem.

Como limitações, as premissas de uso não foram medidas em ambiente hospitalar real, a capacidade das consultas na nuvem foi extrapolada a partir de medição local e os preços são referências públicas aproximadas. Como trabalhos futuros, sugerem-se: repetir o cenário C03 com o algoritmo *least outstanding requests*; testar uma mistura realista de operações na AWS; e validar os preços com cotações formais.

REFERÊNCIAS

AMAZON WEB SERVICES. **Amazon CloudFront pricing**. Seattle, 2026d. Disponível em: https://aws.amazon.com/cloudfront/pricing/. Acesso em: 9 nov. 2026.

AMAZON WEB SERVICES. **Amazon S3 pricing**. Seattle, 2026c. Disponível em: https://aws.amazon.com/s3/pricing/. Acesso em: 9 nov. 2026.

AMAZON WEB SERVICES. **AWS Fargate pricing**. Seattle, 2026b. Disponível em: https://aws.amazon.com/fargate/pricing/. Acesso em: 9 nov. 2026.

AMAZON WEB SERVICES. **AWS Pricing Calculator**. Seattle, 2026a. Disponível em: https://calculator.aws/. Acesso em: 9 nov. 2026.

AMAZON WEB SERVICES. **Elastic Load Balancing pricing**. Seattle, 2026e. Disponível em: https://aws.amazon.com/elasticloadbalancing/pricing/. Acesso em: 9 nov. 2026.

BRASIL. Lei nº 12.965, de 23 de abril de 2014. Estabelece princípios, garantias, direitos e deveres para o uso da Internet no Brasil. **Diário Oficial da União**: seção 1, Brasília, DF, 24 abr. 2014. Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2011-2014/2014/lei/l12965.htm. Acesso em: 9 nov. 2026.

BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). **Diário Oficial da União**: seção 1, Brasília, DF, 15 ago. 2018a. Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm. Acesso em: 9 nov. 2026.

BRASIL. Lei nº 13.787, de 27 de dezembro de 2018. Dispõe sobre a digitalização e a utilização de sistemas informatizados para a guarda, o armazenamento e o manuseio de prontuário de paciente. **Diário Oficial da União**: seção 1, Brasília, DF, 28 dez. 2018b. Disponível em: https://www2.camara.leg.br/legin/fed/lei/2018/lei-13787-27-dezembro-2018-787543-publicacaooriginal-157119-pl.html. Acesso em: 9 nov. 2026.

CONSELHO FEDERAL DE MEDICINA. **CFM esclarece regras para descarte de prontuários médicos após 20 anos**. Brasília, DF, 2026. Disponível em: https://portal.cfm.org.br/noticias/cfm-esclarece-regras-para-descarte-de-prontuarios-medicos-apos-20-anos. Acesso em: 9 nov. 2026.

CONSELHO FEDERAL DE MEDICINA. **Resolução CFM nº 1.821, de 11 de julho de 2007**. Aprova as normas técnicas concernentes à digitalização e uso dos sistemas informatizados para a guarda e manuseio dos documentos dos prontuários dos pacientes. Brasília, DF: CFM, 2007.

MONGODB. **MongoDB Atlas pricing**. New York, 2026. Disponível em: https://www.mongodb.com/pricing. Acesso em: 9 nov. 2026.